

1. SELECCIÓN DATASET EN GEO:

ID: GSE152075 — "Host transcriptional response to SARS-CoV-2 infection"

Estudio de RNA-seq bulk que compara muestras de pacientes infectados por SARS-CoV-2 (casos) frente a sujetos sanos (controles). Incluye una matriz de conteos y metadata con información clínica.

<https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE152075>

The screenshot shows the NCBI GEO Accession Display page for GSE152075. The page includes a navigation bar with links to HOME, SEARCH, SITE MAP, GEO Publications, FAQ, MIAME, and Email GEO. The main content area displays the series information for GSE152075, including the status (Public on Jun 22, 2020), title (In vivo antiviral host response to SARS-CoV-2 by viral load, sex, and age [dataset I]), organism (Homo sapiens), experiment type (Expression profiling by high throughput sequencing), and a detailed summary of the study. The overall design is described as an examination of differential expression of host genes in response to SARS-CoV-2 infection. The contributor is Lieberman N, Greninger A, and the citation is Lieberman NAP, Peddu V, Xie H, Shrestha L et al. In vivo antiviral host transcriptional response to SARS-CoV-2 by viral load, sex, and age. *PLoS Biol* 2020 Sep;18(9):e3000849. PMID: 32898168.

2. DESCARGA DE LA MATRIZ DE EXPRESIÓN + METADATA (CASO/CONTROL)

Realizamos la descarga en GEO:

- **GSE152075_raw_counts.txt** → matriz de expresión
- **GSE152075_series_matrix.txt** → contiene metadata

The screenshot shows the download options for GSE152075. It includes a table with columns for Download family, Format, Supplementary file, Size, Download, and File type/resource. The download family options are SOFT formatted family file(s), MINiML formatted family file(s), and Series Matrix File(s). The format options are SOFT, MINiML, and TXT. The supplementary file is GSE152075_raw_counts_GEO.txt.gz, with a size of 6.8 Mb. The download link is (ftp)(http). The file type/resource is TXT. A note states: "Raw data not provided for this record. Processed data are available on Series record."

Introducimos los documentos descargados en una carpeta creada para esta actividad y comprobamos que se encuentran ahí:

```
(base) bellido17@Ubuntu:~/proyecto_GSE152075$ ls -lh
total 6.9M
-rw-rw-r-- 1 bellido17 bellido17 6.8M Nov 21 16:11 GSE152075_raw_counts_GEO.txt.gz
-rw-rw-r-- 1 bellido17 bellido17 15K Nov 21 16:03 GSE152075_series_matrix.txt.gz
```

3. CARGAMOS LOS DATOS EN R Y ANALIZAMOS

-Observamos que la dimensión de la matriz es de 35.784 genes x 484 muestras. Las primeras columnas y filas de la matriz las podemos ver en la siguiente imagen:

```
> dim(counts)
[1] 35784 484
> head(counts[, 1:6])
      POS_001 POS_002 POS_003 POS_004 POS_005 POS_006
A1BG         0         1         0         0        18         8
A1CF         0         0         2         0         0         0
A2M          69        36        84        42        83        46
A2ML1         2         0         0         0         3        30
A2MP1         0         0         0         0        21         0
A3GALT2       0         0         0         0         0         0
> colnames(counts)[1:10]
[1] "POS_001" "POS_002" "POS_003" "POS_004" "POS_005"
[6] "POS_006" "POS_007" "POS_008" "POS_009" "POS_010"
```

-Extraemos la metadata desde series_matrix.txt. Sacamos los IDs y títulos de las muestras de series_matrix.txt. Las muestras que empiezan con POS_ son case y las que empiezan con NEG_ son control.

```
> head(sample_info)
      sample  title class
1 GSM4602241 POS_001 case
2 GSM4602242 POS_002 case
3 GSM4602243 POS_003 case
4 GSM4602244 POS_004 case
5 GSM4602245 POS_005 case
6 GSM4602246 POS_006 case
> table(sample_info$class)

case control
430      54
```

-Aplicamos un **filtrado** de baja expresión usando filterByExpr (edgeR), lo que permitió eliminar genes con escasa información para el análisis.

- 24.500 genes no tienen expresión suficiente en las muestras, se descartan.
- 11.284 genes sí tienen expresión relevante, se mantienen.

```
> keep <- filterByExpr(dge, group = sample_info$class)
> table(keep)
keep
FALSE TRUE
24500 11284
```


Después realizamos la **normalización TMM** (calcNormFactors) para corregir diferencias en profundidad de secuenciación. Finalmente transformamos los datos a log2-CPM, la forma estándar para análisis exploratorios. Tras el filtrado, se conservaron 11.284 genes,

el dataset ahora contiene los genes informativos pero conserva todas las muestras del estudio.


```
> dim(lcpm)
[1] 11284 484
```

De los 36.000 genes iniciales, nos quedamos con unos 11.000 que realmente están expresados. Luego normalizamos y transformamos los datos, dejando la matriz lista para análisis como PCA, clustering y expresión diferencial.

El **PCA** muestra que los controles son bastante homogéneos mientras que los casos están muy dispersos. No existe una separación clara entre case y control en PC1 y PC2, lo que sugiere que las diferencias globales de expresión no son muy marcadas o que los casos contienen subgrupos muy variables.



-**Heatmap** de correlación entre muestras: la matriz de correlación muestra que la mayoría de las muestras son relativamente similares entre sí, pero existe un subgrupo que se diferencia del resto. Esto sugiere que sí hay diferencias globales de expresión relacionadas con la infección, aunque no forman dos grupos totalmente separados.




Realizamos un **t-test** por gen usando los valores log2-CPM para comparar muestras POS vs NEG. Se ajustaron los p-valores por FDR (Benjamini-Hochberg) y se generó la tabla completa (ttest_results_full.csv), mostrando los 10 genes más significativos.

```
> head(res_df, 10)
```

	stat	p.value	gene
AL022578.1	16.94598	1.106738e-49	AL022578.1
CXCL11	18.52622	1.825570e-47	CXCL11
CXCR2P1	15.52406	3.767857e-38	CXCR2P1
CCN5	15.21067	1.231539e-37	CCN5
CXCL10	19.00125	3.419151e-37	CXCL10
SYNP02L	14.40086	3.944172e-34	SYNP02L
OSR1	13.01727	3.377682e-31	OSR1
WNT7A	12.38872	1.352728e-30	WNT7A
MS4A4A	12.71672	1.998874e-28	MS4A4A
SEMA6D	12.38200	2.651207e-26	SEMA6D

	adj.p
AL022578.1	1.248843e-45
CXCL11	1.029987e-43
CXCR2P1	1.417217e-34
CCN5	3.474170e-34
CXCL10	7.716341e-34
SYNP02L	7.417673e-31
OSR1	5.444824e-28
WNT7A	1.908023e-27
MS4A4A	2.506144e-25
SEMA6D	2.991622e-23

Se seleccionaron los 100 genes con menor FDR y se generó un **heatmap** con valores log2-CPM estandarizados (Z-score). El heatmap muestra patrones de expresión diferenciados entre las muestras POS y NEG, indicando la presencia de genes asociados con la infección por SARS-CoV-2.



Por último, se generaron **boxplots** para los seis genes más significativos (AL022578.1, CCN5, CXCL10, CXCL11, CXCR2P1 y SYNPO2L). En todos ellos se observa una clara diferencia de expresión diferencial entre muestras 'case' y 'control', lo que sugiere que estos genes están asociados con la condición estudiada y podrían contribuir a la respuesta inmunológica ante SARS-CoV-2.

Boxplots de los 6 genes más significativos

