

INFORME DE INTEGRACIÓN MULTIÓMICA PARA LA CLASIFICACIÓN DE CÁNCER VS. SANO

Nombre: Antonio Bellido Maya

Asignatura: Bioinformática e integración de datos en biomedicina

1. Descripción del Pipeline y Procesamiento de Datos

El objetivo de este análisis ha sido construir un flujo de trabajo reproducible para la clasificación de muestras (cáncer vs. sanas) a partir de cuatro capas de datos ómicos: expresión génica (RNA-seq), metilación del ADN (Epigenética), variantes de nucleótido simple (SNV) y variaciones en el número de copias (CNV).

El pipeline de procesamiento se estructuró en las siguientes fases:

- **Carga y Transposición:** los datos se importaron directamente desde las pestañas del archivo excel original. Para los conjuntos de RNA-seq y Epigenética, se transpusieron las matrices para asegurar que las filas representaran a los pacientes y las columnas a las características moleculares (genes/marcas).
- **Transformación de SNV:** los datos de mutaciones, presentados originalmente en formato largo, se transformaron mediante una tabulación cruzada en una matriz binaria (1 = gen mutado, 0 = gen no mutado).
- **Procesamiento de CNV:** se generó un identificador único por región genómica (concatenando cromosoma, inicio y fin). Posteriormente, se pivotó la tabla y se imputaron los valores faltantes con 0, asumiendo un estado diploide normal ($\log_2 \text{ratio} = 0$) en ausencia de alteraciones registradas.
- **Alineación y Normalización:** se forzó a todas las matrices a compartir el mismo orden de pacientes según los metadatos utilizando el método `.reindex()`. Finalmente, las variables continuas (RNA y Epig) se normalizaron mediante estandarización Z-score (`StandardScaler`) para evitar que diferencias en las escalas de medida sesgaran el aprendizaje del algoritmo. La variable objetivo (fenotipo) se codificó binariamente (sano = 0, cáncer = 1).

2. Estrategias de Integración Utilizadas

Para evaluar la mejor forma de combinar la información biológica, se implementaron dos arquitecturas de integración multiómica:

1. **Early Fusion (Fusión Temprana):** se concatenaron horizontalmente las cuatro matrices preprocesadas (RNA, Epig, SNV, CNV) a nivel de características, generando una matriz global única de alta dimensionalidad (126 variables) que se introdujo directamente en el modelo predictivo.
2. **Late Fusion (Fusión Tardía):** se entrenaron cuatro modelos independientes, uno exclusivo para cada tipo de dato ómico. Posteriormente, se combinaron las predicciones de los cuatro "expertos" mediante un sistema de votación por mayoría (ensamble algorítmico) para emitir el diagnóstico final.

3. Justificación de Decisiones Metodológicas

- **Elección del algoritmo (Random Forest):** Se seleccionó *Random Forest* como clasificador base debido a su robustez frente a la "maldición de la dimensionalidad" (datasets donde el número de características p es mucho mayor que el número de muestras n) y su capacidad intrínseca para manejar relaciones no lineales y proporcionar métricas de importancia de variables (*Feature Importance*).
- **Validación Leave-One-Out (LOOCV):** Dado el tamaño extremadamente reducido de la cohorte ($n=10$ muestras), dividir el dataset en subconjuntos tradicionales de entrenamiento y prueba resultaría en una pérdida inaceptable de poder estadístico. LOOCV permite entrenar con $n-1$ muestras y validar iterativamente, maximizando el uso de los datos disponibles y reduciendo el sesgo en la estimación del rendimiento.

4. Problemas Encontrados y Soluciones

Durante el desarrollo del flujo de trabajo, se identificaron y resolvieron dos contratiempos técnicos comunes en el procesamiento de datos ómicos:

- **Error de indexación por sensibilidad a mayúsculas (Case-sensitivity):** al intentar generar la matriz de mutaciones (SNV), se produjo un `KeyError`. Tras inspeccionar el objeto `DataFrame`, se identificó que el código intentaba acceder a las columnas como 'Sample' y 'Gene', mientras que en el archivo fuente estaban etiquetadas en minúsculas ('sample' y 'gene').
 - **Solución:** se corrigió la sintaxis de la función `pd.crosstab` para que coincidiera exactamente con las cabeceras del Excel, permitiendo la correcta binariación de las mutaciones.
- **Error de dimensionalidad en la Fusión Temprana:** al utilizar la función `pd.concat` para integrar las cuatro capas ómicas, inicialmente se omitió el parámetro `axis=1`. Esto provocó que Python "apilara" las tablas una debajo de otra (verticalmente), resultando en una matriz incorrecta de 40 filas en lugar de los 10 pacientes de la cohorte.
 - **Solución:** se especificó el eje de concatenación horizontal (`axis=1`), asegurando que las características de RNA, Epigenética, SNV y CNV se alinearan correctamente para cada paciente, manteniendo la integridad de la matriz multiómica para el modelo Random Forest.

5. Comparación de Enfoques y Limitaciones (Early vs. Late Fusion)

Ambas estrategias, tanto Early Fusion como Late Fusion, alcanzaron una precisión (*Accuracy*) del **100%** en la clasificación (0 falsos positivos, 0 falsos negativos), evidenciado en sus respectivas matrices de confusión.

Capacidad crítica e identificación de limitaciones:

Aunque matemáticamente el modelo es perfecto, desde un punto de vista biológico y estadístico un 100% de precisión en una cohorte tan pequeña sugiere dos posibles escenarios:

1. **Sobreajuste (Overfitting):** A pesar de usar LOOCV, los algoritmos pueden haber memorizado el ruido de los 10 pacientes.
2. **Fuerte señal biológica:** Al tratarse de un conjunto de datos altamente curado para fines académicos, las diferencias moleculares entre sanos y enfermos son tan extremas que cualquier modelo es capaz de separarlos fácilmente. En un entorno clínico real, la heterogeneidad tumoral haría que modelos de un solo ómico (en la estrategia Late Fusion) presentaran un rendimiento inferior, haciendo destacar el valor añadido de la integración multiómica real.

6. Interpretación Biológica de Resultados

Para comprender los determinantes biológicos detrás de las predicciones, se extrajo la importancia de variables del modelo global. El "Top 10" de biomarcadores más predictivos confirma que el modelo ha capturado vías oncogénicas reales y no artefactos matemáticos:

- **Vía de inflamación y supervivencia:** El gen *NFKBIE* apareció como la variable más discriminativa. Este gen codifica para un inhibidor de NF- κ B; su alteración sugiere una desregulación en la transcripción celular y evasión de la apoptosis, características clásicas del cáncer.
- **Oncogenes y Supresores de Tumores Clásicos:** La alta importancia asignada a *TP53* (el guardián del genoma), junto con oncogenes altamente conocidos como *MYC* (factor de transcripción) y *KRAS* (proliferación celular), demuestra que la red de características seleccionada refleja alteraciones críticas para la tumorigénesis.
- **Interacciones complejas:** El emparejamiento de *FBXW7* y *NOTCH1* en el top 10 indica un reconocimiento del modelo de vías de degradación proteica fallidas típicas en diversas neoplasias.
- **Alteraciones Estructurales (CNV):** Es notable la presencia de regiones genómicas completas (como chr10_47750000_49250000 y chr15_20625000_22625000) entre los biomarcadores principales. Esto subraya que grandes eventos de inestabilidad cromosómica (ganancias o deleciones) aportan tanto valor diagnóstico como las mutaciones puntuales o los cambios de expresión en este conjunto de datos.

7. Referencias Bibliográficas

1. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
2. Hanahan, D., & Weinberg, R. A. (2011). Hallmarks of cancer: the next generation. *Cell*, 144(5), 646-674.
3. McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51-56.
4. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.